

TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN
ĐẠI HỌC QUỐC GIA TP.HCM

BÁO CÁO ĐỒ ÁN

**One Embedder, Any Task: Instruction-Finetuned Text
Embeddings**

Giảng viên hướng dẫn: TS. Nguyễn Thị Quý

Sinh viên thực hiện: Lê Phạm Minh Triết – 23521651

Nguyễn Võ Ngọc Bảo – 23520131

Nguyễn Phương Quyên – 23521327

Lớp: Xử lý ngôn ngữ tự nhiên – CS221.Q12

Mục lục

1	Tổng quan đồ án	1
2	Phương pháp	1
2.1	Định dạng đầu vào và embedding	1
2.2	Thiết kế thí nghiệm	1
3	Dataset	1
4	Cài đặt và triển khai	2
4.1	Cài đặt	2
4.2	Chạy demo	2
5	Kết quả	2
6	Kết luận	2

1 Tổng quan đề án


Đề án triển khai lại ý tưởng của bài báo *INSTRUCTOR* với mục tiêu tạo **text embeddings** “theo nhiệm vụ” bằng cách đưa **instruction** vào đầu vào encoder. Nhóm xây dựng notebook demo để:

- So sánh **GTR-T5** (backbone, không instruction) và **INSTRUCTOR** (fine-tuned với instruction) trên retrieval và clustering.
- Minh hoạ tính chất *One Embedder, Any Task*: cùng một câu nhưng instruction khác $\Rightarrow$ embedding khác.
- Đánh giá nhanh trên các triplet query-pos-neg của bộ dữ liệu huấn luyện đa nhiệm (MEDI) bằng các độ đo truy hồi.

2 Phương pháp

2.1 Định dạng đầu vào và embedding

Mỗi mẫu được đưa về dạng cặp [instruction, text]. Encoder (T5-style) sinh vector đại diện, sau đó dùng **cosine similarity** để so sánh/nghiệm thu.



2.2 Thiết kế thí nghiệm

Retrieval: embed query (instruction “question for retrieving...”), embed corpus (instruction “document for retrieval”), xếp hạng theo cosine. **Clustering:** embed văn bản với instruction “topic clustering”, chạy KMeans; đánh giá bằng *Silhouette* và *ARI*. **MEDI triplets:** với mỗi query, so sánh $sim(q, p^+)$ và $sim(q, n)$, đồng thời đo **Recall@K** và **MRR** trên corpus ghép từ pos/neg.

3 Dataset

Notebook sử dụng hai nguồn dữ liệu:

- **Toy dataset** (nhỏ) để minh hoạ retrieval/clustering theo chủ đề (Sports/Technology/Food).
- **MEDI-style triplets** lưu trong `input/medi-data.json`, mỗi mẫu gồm query, pos, neg và task_name; nhóm lấy mẫu theo nhiều task retrieval (vd. msmarco, fever, TriviaQA...).

4 Cài đặt và triển khai

4.1 Cài đặt

1. `git clone`
→ <https://github.com/AdamNbz/CS221.git>
2. `cd CS221/instructor-embedding`
3. `conda create -n instructor python=3.9 -y`
`conda activate instructor`
`pip install -r requirements.txt`
`pip install -e .`

4.2 Chạy demo

Chạy lần lượt các phần trong `demo.ipynb`: (i) retrieval + heatmap similarity, (ii) task-specific instructions, (iii) retrieval metrics (Recall@K, MRR) trên corpus lớn hơn, (iv) clustering + t-SNE, và (v) thử nghiệm trên MEDI triplets.

5 Kết quả

Clustering (toy data): Silhouette tăng từ **0.0861** (GTR-T5) lên **0.1329** (INSTRUCTOR); ARI đạt 1.0 cho cả hai (dữ liệu nhỏ, cụm rõ).

Retrieval (MEDI subset, 200 queries / 400 docs): INSTRUCTOR cải thiện đồng đều các độ đo:

Metric	GTR-T5	INSTRUCTOR	Δ
Recall@1	0.8250	0.8450	+0.0200
Recall@3	0.9250	0.9750	+0.0500
Recall@5	0.9450	0.9950	+0.0500
Recall@10	0.9800	1.0000	+0.0200
MRR	0.8853	0.9100	+0.0247

Quan sát định tính cho thấy embedding có instruction tạo *margin* tốt hơn ở nhiều mẫu, giúp xếp hạng đúng tài liệu liên quan.

6 Kết luận

Nhóm đã hoàn thiện pipeline demo cho INSTRUCTOR: nạp mô hình, tạo embedding có điều kiện theo instruction, và kiểm chứng qua retrieval/clustering. Kết quả cho thấy **instruction** là tín hiệu quan trọng để “nhiệm vụ hoá” embedding, giúp một encoder có thể tái sử dụng cho nhiều bài toán.

Hướng phát triển: (i) mở rộng sang đa ngôn ngữ, (ii) chuẩn hoá bộ instruction cho từng họ tác vụ, (iii) tối ưu triển khai (ví dụ quantization để giảm kích thước và tăng tốc suy luận).